

北京信息科技大学

毕业设计（论文）

题目：面向信号干扰检测与识别的视频传输平台开发

学院：信息与通信工程学院

专业：通信工程（卓越）

学生姓名：李智杰 班级/学号：通信2201 / 2022010843

指导老师/督导老师：刘磊

起止时间：2026年2月23日至2026年5月20日

毕业设计（论文）原创性声明

本人郑重声明：所呈交的毕业设计（论文），题目为《面向信号干扰检测与识别的视频传输平台开发》，是本人在导师指导下，进行研究工作所取得的成果。尽我所知，除了文中特别加以标注的内容外，本毕业设计（论文）的研究成果不包含任何他人创作的、已公开发表或者没有公开发表的作品的内容。对本毕业设计（论文）所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明并表示了谢意。本毕业设计（论文）原创性声明的法律责任由本人承担。

作者签名：

2026年5月20日

毕业设计（论文）版权授权声明

本人完全了解北京信息科技大学关于收集、保存、使用本科生毕业设计（论文）的要求，按照学校要求提交毕业设计（论文）的印刷本和电子版本。学校有权保留毕业设计（论文）并向相关机构送交论文的电子版和纸质版，允许论文被查阅和借阅，可以采用影印、缩印或扫描等复制手段保存、汇编毕业设计（论文）。学校有权适当复制、公布论文的全部或部分内容。

指导教师签名： 作者签名：

2026年5月20日 2026年5月20日

摘要

随着5G/6G通信系统向高频段、大带宽和高密度连接方向发展,复杂电磁环境中的同频、邻频及恶意干扰会显著降低视频业务链路质量。为提升通信系统对干扰态势的感知能力和视频传输可靠性,本文设计并实现了一套面向信号干扰检测与识别的自适应视频传输平台。平台以USRP B210软件无线电为硬件基础,构建了覆盖视频采集、JPEG编码、帧结构分包、前向纠错、QPSK调制解调、信道传输、干扰识别和传输策略调整的完整链路。

在干扰识别方面,本文构建了复合卷积神经网络CCNN模型,融合卷积特征提取、残差学习、SE通道注意力和多头因果注意力机制,实现对扫频、多音、窄带调幅、窄带调频、单音、正弦波及正常信号共7类样本的识别。实验结果表明,模型在JSR不低于0 dB时识别准确率达到99.9%,在JSR=-2 dB条件下仍保持较高鲁棒性。系统测试结果显示,平台能够根据识别结果动态调整JPEG质量、FEC冗余和帧率,完成仿真模式与USRP实机模式下的闭环验证。

关键词: 干扰识别; 卷积神经网络; 自适应传输; 软件无线电; USRP B210

Abstract

With the evolution of 5G and 6G communication systems toward wider bandwidth, higher carrier frequency, and denser network deployment, co-channel, adjacent-channel, and intentional jamming may seriously degrade the quality of video transmission links. To improve interference awareness and transmission reliability in complex electromagnetic environments, this thesis designs and implements an adaptive video transmission platform for signal interference detection and recognition. Based on the USRP B210 software-defined radio, the platform integrates video capture, JPEG encoding, packet framing, forward error correction, QPSK modulation and demodulation, channel transmission, interference recognition, and adaptive parameter control into a complete end-to-end chain.

For interference recognition, a composite convolutional neural network, named CCNN, is constructed by combining convolutional feature extraction, residual learning, squeeze-and-excitation channel attention, and multi-head causal attention. The model classifies seven categories, including linear frequency modulation jamming, multi-tone jamming, narrowband amplitude modulation jamming, narrowband frequency modulation jamming, single-tone jamming, sinusoidal jamming, and clean signals. Experimental results show that the recognition accuracy reaches 99.9% when JSR is not lower than 0 dB and remains robust at JSR = -2 dB. System tests further demonstrate that the proposed platform can dynamically adjust JPEG quality, FEC redundancy, and frame rate according to recognition results, and can complete closed-loop verification in both simulation and USRP hardware-in-the-loop modes.

Keywords: Interference Recognition; Convolutional Neural Network; Adaptive Transmission; Software-Defined Radio; USRP B210

目录

摘要

Abstract

第一章 绪论

- 1.1 研究背景与意义
- 1.2 国内外研究现状
 - 1.2.1 干扰信号检测与识别
 - 1.2.2 软件无线电平台应用
 - 1.2.3 自适应传输技术
- 1.3 本文主要工作
- 1.4 论文组织结构

第二章 系统相关技术

- 2.1 软件无线电与USRP B210
- 2.2 QPSK调制解调
- 2.3 卷积神经网络
- 2.4 注意力机制
 - 2.4.1 SE通道注意力
 - 2.4.2 多头因果注意力
- 2.5 残差网络
- 2.6 前向纠错编码

第三章 系统总体设计

- 3.1 系统架构
- 3.2 系统运行模式
- 3.3 系统参数配置
- 3.4 线程模型

第四章 干扰识别模型设计与实现

- 4.1 干扰信号模型
 - 4.1.1 扫频干扰 (LFM)
 - 4.1.2 多音干扰 (MTJ)
 - 4.1.3 窄带调幅干扰 (NAM)
 - 4.1.4 窄带调频干扰 (NFM)
 - 4.1.5 单音干扰 (STJ)
 - 4.1.6 正弦波干扰 (SIN)
- 4.2 CCNN网络结构设计
 - 4.2.1 网络总体架构
 - 4.2.2 CNN特征提取模块
 - 4.2.3 残差网络模块
 - 4.2.4 多头因果注意力模块
 - 4.2.5 分类器模块
- 4.3 训练数据生成
 - 4.3.1 数据生成方案
 - 4.3.2 数据集构成
 - 4.3.3 数据预处理

4.4 模型训练
4.4.1 训练配置
4.4.2 训练结果
4.5 JSR鲁棒性测试
4.6 MATLAB与Python数据生成对比
第五章 视频传输系统设计与实现
5.1 TX端设计
5.1.1 视频源模块
5.1.2 JPEG编码与FEC编码
5.1.3 QPSK调制
5.1.4 数据帧结构设计
5.2 RX端设计
5.2.1 信号接收与预处理
5.2.2 QPSK解调
5.2.3 FEC解码与JPEG解码
5.3 干扰检测流程
5.3.1 功率谱特征提取
5.3.2 CCNN 7类直接识别
5.4 自适应传输策略
5.4.1 干扰等级划分
5.4.2 滞后切换机制
5.5 实时可视化
第六章 系统测试与实验分析
6.1 实验环境
6.2 CCNN模型性能测试
6.2.1 整体分类性能
6.2.2 JSR鲁棒性分析
6.2.3 各干扰类型误判分析
6.3 CCNN模型计算复杂度分析
6.3.1 参数量与计算量
6.3.2 与其他方法对比
6.4 仿真模式系统测试
6.4.1 正常传输测试
6.4.2 自动演示测试
6.5 USRP实机模式测试
6.5.1 硬件识别与配置核对
6.5.2 CCNN与自适应策略核对结果
6.5.3 历史JSR扫描与实机识别现象
6.5.4 USRP实时可视化长测
6.6 自适应策略有效性验证
结束语
1 本文工作总结
2 不足与展望
参考文献

摘要

Abstract

第一章 绪论

1.1 研究背景与意义

1.2 国内外研究现状

1.2.1 干扰信号检测与识别

1.2.2 软件无线电平台应用

1.2.3 自适应传输技术

1.3 本文主要工作

1.4 论文组织结构

第二章 系统相关技术

2.1 软件无线电与USRP B210

2.2 QPSK调制解调

2.3 卷积神经网络

2.4 注意力机制

2.4.1 SE通道注意力

2.4.2 多头因果注意力

2.5 残差网络

2.6 前向纠错编码

第三章 系统总体设计

3.1 系统架构

3.2 系统运行模式

3.3 系统参数配置

3.4 线程模型

第四章 干扰识别模型设计与实现

4.1 干扰信号模型

4.1.1 扫频干扰 (LFM)

4.1.2 多音干扰 (MTJ)

4.1.3 窄带调幅干扰 (NAM)

4.1.4 窄带调频干扰 (NFM)

4.1.5 单音干扰 (STJ)

4.1.6 正弦波干扰 (SIN)

4.2 CCNN网络结构设计

- 4.2.1 网络总体架构
- 4.2.2 CNN特征提取模块
- 4.2.3 残差网络模块
- 4.2.4 多头因果注意力模块
- 4.2.5 分类器模块
- 4.3 训练数据生成
 - 4.3.1 数据生成方案
 - 4.3.2 数据集构成
 - 4.3.3 数据预处理
- 4.4 模型训练
 - 4.4.1 训练配置
 - 4.4.2 训练结果
- 4.5 JSR鲁棒性测试
- 4.6 MATLAB与Python数据生成对比
- 第五章 视频传输系统设计与实现
 - 5.1 TX端设计
 - 5.1.1 视频源模块
 - 5.1.2 JPEG编码与FEC编码
 - 5.1.3 QPSK调制
 - 5.1.4 数据帧结构设计
 - 5.2 RX端设计
 - 5.2.1 信号接收与预处理
 - 5.2.2 QPSK解调
 - 5.2.3 FEC解码与JPEG解码
 - 5.3 干扰检测流程
 - 5.3.1 功率谱特征提取
 - 5.3.2 CCNN 7类直接识别
 - 5.4 自适应传输策略
 - 5.4.1 干扰等级划分
 - 5.4.2 滞后切换机制
 - 5.5 实时可视化
- 第六章 系统测试与实验分析
 - 6.1 实验环境

6.2 CCNN模型性能测试

6.2.1 整体分类性能

6.2.2 JSR鲁棒性分析

6.2.3 各干扰类型误判分析

6.3 CCNN模型计算复杂度分析

6.3.1 参数量与计算量

6.3.2 与其他方法对比

6.4 仿真模式系统测试

6.4.1 正常传输测试

6.4.2 自动演示测试

6.5 USRP实机模式测试

6.5.1 硬件识别与配置核对

6.5.2 CCNN与自适应策略核对结果

6.5.3 历史JSR扫描与实机识别现象

6.5.4 USRP实时可视化长测

6.6 自适应策略有效性验证

结束语

1 本文工作总结

2 不足与展望

参考文献

第一章 绪论

1.1 研究背景与意义

从工程应用角度看，视频业务链路不仅要求较高的数据吞吐量，还要求端到端时延、丢包率和画面连续性同时满足约束。当通信链路受到窄带或扫频干扰时，接收端首先表现为信噪比下降、同步序列检测不稳定和误码率上升，随后才体现为视频画面卡顿、马赛克或中断。因此，若系统只能在视频质量已经明显下降后再被动调参，往往难以及时恢复链路质量。本文将干扰检测识别前置到物理层和基带信号处理阶段，通过对IQ样本和功率谱特征的分析提前获取信道异常信息，再把识别结果反馈给视频传输控制模块，为上层编码质量和冗余策略调整提供依据。

与传统固定参数的视频传输方案相比，干扰感知型传输平台更强调跨层协同：物理层负责采集和还原信号状态，算法层负责判断干扰类型和可信度，应用层则根据链路状态动态改变视频编码质量、FEC冗余和帧率。这样的设计能够在不同干扰强度下取得可靠性与实时性的折中。在无干扰或轻度干扰场景中，系统优先保证较高帧率和画面清晰度；在强干扰场景中，系统牺牲部分视觉质量以提升解码成功率，从而避免视频链路完全中断。这种策略符合智能通信系统由静态配置向环境自适应演进的发展趋势。

结合本人早期论文过程稿的论述，本课题的研究对象并不是单纯的离线干扰分类，而是面向视频业务的链路可靠性保障。视频业务对通信质量十分敏感，一旦干扰在毫秒级时间尺度上造成误码率上升，接收端就可能出现花屏、卡顿或帧丢失。因此，系统需要在业务质量明显恶化前尽早感知信道状态，并把干扰识别结果转化为可执行的传输参数调整。

在6G候选应用场景中，无人机、车联网、应急通信和密集异构网络会使频谱占用更加动态，通信链路面对的同频、邻频和恶意干扰也更复杂。这使得传统依靠固定阈值或固定抗干扰参数的方案难以长期保持稳定性能。本文围绕USRP软件无线电、深度学习识别和自适应视频传输三个层面展开，目的是构建一个能够从仿真走向实机验证的工程原型，而不仅是完成单项算法指标测试。

随着无线通信技术的快速发展，电磁环境日益复杂。在军事通信、应急通信和民用通信等领域，通信系统面临各种类型的故意或无意干扰威胁。这些干扰可能导致通信质量严重下降甚至通信中断，对信息安全传输构成重大威胁。

传统的干扰检测方法主要基于功率谱密度（PSD）分析、统计特征提取等信号处理技术，通过设定固定阈值进行干扰判决。这类方法虽然在特定条件下有效，但存在以下局限性：（1）依赖人工特征设计，泛化能力有限；（2）难以区分不同类型的干扰信号；（3）对低干信比（JSR）条件下干扰检测灵敏度不足。

近年来，深度学习技术在信号识别领域展现出强大能力[25]。卷积神经网络（CNN）能够自动学习信号的特征表示，在调制识别、信号分类等任务中取得了显著优于传统方法的性能。将深度学习应用于干扰检测与识别，能够实现更高精度的干扰类型判别，为后续的自适应抗干扰策略提供更精确的决策依据。

1.2 国内外研究现状

1.2.1 干扰信号检测与识别

现有干扰识别研究大致可分为基于人工特征的方法和基于深度学习的方法。前者通常提取功率谱峰值、谱熵、频率重心、带宽占用率等统计特征，再结合阈值判决、支持向量机或浅层分类器完成识别，其优点是计算量较小、可解释性较强，但对复杂时变干扰和低JSR样本的泛化能力有限。后者直接从IQ序列、频谱图或时频图中学习特征表示，能够减少人工建模对先验知识的依赖，尤其适合多类型干扰混合、信道参数不确定的场景。本文采用以深度网络为核心、以功率谱特征为辅助的方案，既保留传统方法对能量变化敏感的优势，又利用神经网络增强类别区分能力。

在网络结构选择上，单纯CNN擅长提取局部波形和频谱纹理，但对长序列范围内的上下文依赖建模不足；循环网络具有时序表达能力，但训练效率和并行计算能力相对受限；Transformer类结构能够刻画长距离依赖，却需要解决一维信号局部细节提取不足的问题。基于上述考虑，本文的CCNN模型采用复合结构，将卷积、残差连接、通道注意力和因果注意力组合起来，使模型同时具备局部细节感知、梯度稳定传播、通道重要性重标定和时序上下文建模能力。该结构与论文任务中的实时干扰识别需求具有较好匹配性。

在干扰检测领域，国内外学者已开展了大量研究。Pirayesh和Zeng系统综述了无线网络中的干扰攻击与抗干扰策略，对基于功率谱特征的检测方法进行了全面梳理，指出自适应阈值方案在应对时变干扰时的有效性[4]。基于功率谱幅值分布、谱熵等统计特征的检测方法因其计算复杂度低而得到广泛应用，但在低干信比条件下检测灵敏度不足，且难以区分干扰类型。

在干扰识别领域，深度学习方法的引入显著提升了识别精度。O'Shea等人最早验证了CNN在无线信号分类任务中的有效性，将IQ信号直接作为网络输入，证明了端到端深度学习方法的可行性，奠定了基于深度学习的信号识别研究基础[3]。随后O'Shea等人构建了RadioML数据集并系统评估了CNN在空中射频信号分类中的性能，验证了深度学习方法在真实信道条件下的鲁棒性[21]。Zhang等人提出了CNN与Transformer相结合的干扰识别网络，充分利用了CNN局部特征提取和Transformer全局依赖建模的互补优势，在多种干扰类型上取得了优于纯CNN方法的性能[6]。Savolainen等人提出了双阶段深度学习干扰识别方法，先检测再分类，为级联架构提供了参考[23]。Xu等人提出了基于时频分析的深度干扰分类方法，用于跳频系统的干扰识别，通过时频图变换将一维信号分类转化为二维图像分类问题[7]。Guo等人研究了基于深度学习的干扰信号特征提取与模式分类算法，验证了注意力机制在干扰识别中的有效性[9]。Li等人将深度学习应用于跳频信号的自动调制识别，展示了CNN在复杂电磁环境下的泛化能力[10]。

在国内研究方面，王志勤等人对6G移动通信系统中的关键技术挑战进行了展望，指出智能抗干扰将是未来通信系统的重要能力[1]。张平等人进一步分析了6G场景下通信与人工智能融合的技术路径[2]。

1.2.2 软件无线电平台应用

软件无线电（SDR）技术为干扰检测与识别算法的工程验证提供了灵活的硬件载体。Haykin提出的认知无线电概念[24]为频谱感知与智能通信奠定了理论基础。USRP作为成熟的软件无线电硬件平台，已被广泛应用于通信干扰检测与信号处理研究。Manco等人的综述表明，基于SDR的频谱感知技术在认知无线电领域具有重要的应用价值，USRP平台的高采样率和宽频率范围使其成为实时信号处理的理想工具[8]。在实际应用中，基于USRP的通信系统验证平台能够实现从算法仿真到硬件在环测试的无缝衔接，加速了干扰检测算法的工程化进程。

1.2.3 自适应传输技术

自适应传输技术通过动态调整传输参数来适应信道条件变化。在干扰环境下，自适应策略通常包括调整调制方式、编码速率、发射功率等参数。Proakis[15]和Goldsmith[16]在其经典著作中系统论述了自适应调制编码（AMC）的理论基础，指出基于信道状态信息（CSI）的自适应传输能够在保证服务质量的前提下最大化频谱效率。已有研究表明，结合实时信道感知的自适应传输能够显著提高系统在恶劣信道条件下的传输可靠性。本文将干扰类型识别结果作为信道状态信息，通过调整应用层参数（JPEG质量、FEC冗余度、帧率）实现干扰环境下的传输优化。

1.3 本文主要工作

本文设计并实现了一套完整的干扰感知自适应视频传输系统，主要工作包括：

干扰识别模型设计：基于复合卷积神经网络（CCNN），融合CNN、SE注意力、残差网络和多头因果注意力，实现7类信号（6类干扰+正常信号）的准确分类。

训练数据生成与Python信号生成器开发：初期基于MATLAB实现了6种干扰信号的生成器（16个脚本，1457行代码），后期使用Python精确复现MATLAB逻辑并整合为1个文件（465行），扩展为7类、宽干信比（-2~16 dB）训练数据集，共13,300个样本。Python方案实现了按需在线生成，与系统仿真信道无缝集成。

训练数据质量决定了干扰识别模型的上限。本文围绕六类典型干扰和正常信号构造样本，覆盖不同JSR、频率偏移、相位和噪声条件，使模型在训练阶段能够看到足够多的变化形式。与只在单一信噪比下生成样本相比，宽JSR范围的数据集更接近真实通信环境，能够降低模型对某一固定功率条件的过拟合风险。数据生成过程还保留类别编号、JSR参数和样本划分信息，便于后续复现实验和定位误判来源。

本文同时比较了MATLAB和Python两种数据生成方式。MATLAB脚本便于快速验证单类干扰的数学模型和波形特征，但多脚本结构在批量生成、系统集成和在线仿真方面不够灵活。Python生成器将多类干扰逻辑整合到统一接口中，能够按需生成训练样本，也能够与视频传输仿真信道直接连接。因此，Python方案不仅减少了中间文件存储压力，也使模型训练、推理测试和系统级实验形成更连贯的工作流。

视频传输系统实现：设计了完整的TX/RX链路，包括JPEG编码、自定义帧结构分包、FEC编码、QPSK调制解调（含RRC脉冲成形、前导序列同步、CFO估计校正、AGC）等功能模块。

QPSK调制方式在本系统中承担着连接视频字节流与无线基带信号的关键作用。发送端将经过分包和冗余编码后的比特序列按照两比特一组映射到四个相位点，再通过根升余弦滤波器进行脉冲成形，以降低带外泄漏和符号间干扰。接收端则需要存在噪声、频偏和幅度变化的情况下完成符号判决。由于本文重点是构建可验证的干扰识别与自适应传输平台，QPSK在复杂度、实现难度和实验可解释性之间取得了较好平衡：它比BPSK具有更高频谱效率，又比高阶QAM对信噪比和同步精度的要求更低，适合作为毕业设计阶段软硬件闭环验证的基础调制方案。

在实机链路中，QPSK解调性能受到多个因素共同影响。载波频偏会导致星座图整体旋转，采样时偏会使最佳判决点偏离符号中心，自动增益控制不稳定则会改变星座点幅度分布。本文在接收端加入AGC、前导序列同步和频偏估计校正，目的不是追求通信体制的完整商用化实现，而是保证平台能够在可控实验条件下稳定传递视频分片，并为后续干扰识别模块提供足够可靠的信

号输入。这一设计使系统既能展示完整数字通信链路，也能清楚反映干扰对不同处理环节的影响。

自适应传输策略：根据CCNN的实时检测结果，动态调整JPEG质量、FEC冗余度和帧率，实现干扰环境下的传输参数优化。

自适应传输策略的核心是避免识别结果的瞬时波动直接导致传输参数频繁跳变。实际链路中，模型置信度可能随噪声、同步误差和短时信道衰落而波动，若每一次分类输出都立即触发参数切换，视频质量会出现明显抖动。本文引入多级滞后计数器机制，对干扰出现、干扰等级变化和干扰消失分别设置确认门限。只有连续多次观测满足条件时，系统才改变JPEG质量、FEC倍数和帧率，从而提高策略稳定性。

策略映射关系按照干扰对链路破坏程度进行分级。无干扰时系统采用较高JPEG质量和较高帧率，减少冗余以提升有效吞吐；轻度干扰时适当降低图像质量并提高FEC冗余，使接收端具备更强的分片恢复能力；强干扰时进一步降低帧率和码率，把有限信道资源优先用于保证关键帧能够被正确接收。该策略并不追求单一指标最优，而是在画面清晰度、实时性和可靠性之间实现工程可用的动态平衡。

硬件在环验证：基于USRP B210完成端到端实机测试，验证系统实用性。

实时可视化：开发matplotlib可视化面板，实时展示系统运行状态。

1.4 论文组织结构

本文共分为七章。第一章为绪论，介绍研究背景和现状；第二章介绍系统涉及的关键技术；第三章给出系统总体设计方案；第四章详细描述CCNN干扰识别模型的设计与训练；第五章阐述视频传输系统的实现细节；第六章给出系统测试与实验分析；第七章总结全文并展望未来工作。

第二章 系统相关技术

2.1 软件无线电与USRP B210

USRP B210能够在较宽频率范围内完成射频信号收发，并通过UHD驱动向上层软件提供统一接口，适合用于通信算法从仿真到实机的迁移验证。本文选择USRP B210作为硬件平台，主要考虑其双通道收发能力、较高采样率、成熟的软件生态和较低的实验门槛。在系统实现中，USRP负责完成基带IQ数据与射频信号之间的转换，Python程序负责帧封装、调制解调、干扰注入、模型推理和可视化显示。这种软硬件分工既便于快速调试算法，也便于根据实验需要调整采样率、中心频率、增益和缓冲区等关键参数。

根据任务书、旧稿和USRP资料核对，USRP B210的射频收发范围覆盖70 MHz至6 GHz，支持最高56 MHz瞬时带宽，并通过USB 3.0接口与主机连接。UHD驱动为上层Python程序提供统一的设备发现、频率设置、增益控制和IQ数据收发接口。这些特性使其适合承担本课题从软件仿真到硬件在环验证的桥梁。

从系统集成角度看，USRP B210只负责射频前端和IQ采样转换，干扰注入、视频编解码、QPSK调制解调、CCNN推理和可视化仍由上位机软件完成。这种分工降低了硬件开发难度，也使毕业设计能够把主要精力集中在算法验证和链路闭环上。同时，真实硬件带来的频偏、采样时偏、增益波动和USB缓冲限制，也为第六章分析仿真与实机结果差异提供了依据。

软件无线电 (Software-Defined Radio, SDR) 是一种通过软件实现无线电通信系统大部分功能的技术方案。与传统的硬件无线电相比, SDR具有灵活性高、可重构性强、开发周期短等优势。

USRP (Universal Software Radio Peripheral) 是由Ettus Research公司开发的一系列软件无线电外设。本文使用的USRP B210是一款高性能、低成本的SDR平台, 其主要特性如下:

参数	规格
频率范围	70 MHz ~ 6 GHz
通道数	2×2 MIMO
采样率	最高 61.44 MSps
带宽	最高 56 MHz
分辨率	12-bit ADC / 14-bit DAC
接口	USB 3.0
FPGA	Xilinx Spartan-6

系统通过UHD (USRP Hardware Driver) 驱动程序控制USRP B210, 使用Python绑定接口实现参数配置和数据收发。

2.2 QPSK调制解调

四相位移键控 (Quadrature Phase Shift Keying, QPSK) 是一种常用的数字调制方式, 每个符号携带2比特信息。QPSK通过在I (同相) 和Q (正交) 两个正交载波上各传输1比特数据, 实现每符号2比特的传输效率。

本系统采用根升余弦 (Root Raised Cosine, RRC) 脉冲成形滤波器, 滚降系数为0.35, 符号率为500 ksym/s, 采样率为2 MHz (每符号4个采样点), 数据传输速率为1 Mbps。




图2-1 QPSK星座图

2.3 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）是深度学习中最成功的网络结构之一。CNN通过卷积层提取输入数据的局部特征，通过池化层降低特征维度，通过全连接层实现分类决策。CNN在图像识别、语音处理和信号分类等领域均有广泛应用。

一维卷积神经网络（1D-CNN）适用于时序信号的特征提取。O'Shea等人将深度学习引入射频信号分类领域，利用CNN实现了对多种调制方式的自动识别[3][21]。本系统中，CCNN模型使用1D-CNN处理IQ双通道信号（实部和虚部），提取信号的时域特征用于干扰类型分类。

2.4 注意力机制

2.4.1 SE通道注意力

SE-Net（Squeeze-and-Excitation Network）通过学习通道间的依赖关系，自适应地增强重要特征通道。SE模块包含两个操作：（1）Squeeze操作，通过全局平均池化将每个通道压缩为单一数值；（2）Excitation操作，通过全连接层学习通道权重并应用于原始特征。

2.4.2 多头因果注意力

多头注意力机制允许模型同时关注输入序列的不同位置 and 不同表示子空间，由Vaswani等人[12]在Transformer架构中首次提出。因果注意力（Causal Attention）确保每个位置的注意力计算只依赖于当前位置及之前的位置，符合时序信号因果关系。Van Den Oord等人[22]提出的WaveNet首次将因果卷积应用于序列建模，本系统在TCC模块中借鉴了因果卷积的设计思想。

2.5 残差网络

残差网络（Residual Network, ResNet）由He等人提出[13]，通过引入残差连接（Skip Connection）解决深层网络的梯度消失问题。残差块的核心思想是学习残差映射 $F(x) = H(x) - x$ ，而非直接学习目标映射 $H(x)$ 。残差连接使梯度能够通过捷径直接回传至浅层：

本系统中，CCNN模型的残差模块结合了SE通道注意力机制，构成“注意力残差块”：卷积提取特征→SE模块增强重要通道→残差连接保留原始信息，实现了特征增强与梯度传播的平衡。

2.6 前向纠错编码

前向纠错（Forward Error Correction, FEC）是一种通过在发送端添加冗余信息来实现接收端自动纠错的信道编码技术。本系统采用基于XOR的分组冗余编码方案，支持1~3倍冗余度。

编码原理：对于 N 个数据包 $P_0, P_1, \dots, P_{N-1}$ ，生成 R 个冗余包，每个冗余包为所有数据包的按位异或：

当任意一个数据包 P_k 在传输中丢失时，可通过冗余包和其余数据包恢复：

该方案的纠错能力取决于冗余度与丢失包数的关系： R 倍冗余可纠正最多 R 个丢失包。系统在无干扰时使用1倍冗余（无额外开销），轻度/中度干扰使用2倍冗余，严重干扰使用3倍冗余。

上述技术——USRP软件无线电平台的射频收发能力、QPSK调制解调的基带处理、CNN和注意力机制的深度学习特征提取、残差网络的梯度优化能力、以及FEC编码的差错保护——在本系统中协同工作，构成了一个从信号感知到传输优化的完整闭环。下一章将详细介绍这些技术的系统集成方案和总体架构设计。

第三章 系统总体设计

3.1 系统架构

系统总体架构遵循模块化和可替换原则，按照数据流方向划分为发送端、信道/干扰环境、接收端、识别决策模块和可视化模块。发送端实际以系统内置测试图案或视频文件作为输入源获取图像帧，并根据当前策略完成JPEG压缩、分片、添加帧头和CRC校验，再经过FEC冗余编码和QPSK调制生成基带信号。接收端完成采样数据缓存、帧同步、频偏估计、AGC归一化、QPSK解调、FEC恢复、CRC检查和JPEG解码。识别决策模块从接收侧信号中提取用于CCNN推理的片段，并将干扰类别、置信度和干扰等级反馈给发送控制策略。

为了保证系统在仿真和实机两种模式下具有一致的软件接口，本文将信道抽象为统一的数据交换层。在仿真模式中，该层由SimulatedChannel完成，可直接注入不同类型的干扰信号，便于重复实验和参数扫描；在实机模式中，该层由USRP收发链路替代，通过UHD接口完成真实射频采样。上层模块不直接依赖具体信道实现，因此同一套TX/RX逻辑可以在两种模式下运行。这种设计降低了调试复杂度，也使实验结果能够更清晰地反映算法本身和硬件链路之间的差异。

本文设计的干扰感知自适应视频传输系统采用单机环回架构，系统整体结构如图3-1所示。




图3-1 系统总体架构

系统分为TX（发送）端和RX（接收）端两个主要处理链路，通过无线信道（仿真信道或USRP实机）连接。TX端完成视频采集、编码、调制和发送；RX端完成接收、解调、解码和显示。同时，RX端通过CCNN模型对干扰信号进行实时检测与识别，并将检测结果反馈至自适应控制器，动态调整TX端传输参数。

3.2 系统运行模式

系统支持两种运行模式：

模式	信道实现	USRP	适用场景
仿真模式（sim）	SimulatedChannel 软件仿真	不需要	算法开发、模型验证
实机模式（full）	USRP B210 RF收发	需要	硬件验证、实机演示

3.3 系统参数配置

系统参数配置直接影响平台在不同测试场景下的稳定性和可复现实验能力。本文将采样率、中心频率、符号率、JPEG基准质量、FEC冗余倍数、干扰注入强度和模型推理窗口长度等关键参数集中管理，避免这些参数分散在多个模块中造成调试困难。集中配置还有助于保证论文实验与程序实现之间的一致性：当第六章需要对比不同JSR条件下的性能时，只需调整统一配置项即可复现实验，而不需要修改底层算法代码。

参数配置同时体现了仿真模式和实机模式的差异。仿真模式不受硬件带宽、USB缓冲和射频前端非理想因素限制，适合使用较高分辨率和较高JPEG质量验证算法逻辑；实机模式需要考虑USRP采样率、主机处理能力和实时显示开销，因此采用较低视频分辨率和更保守的编码参数。这种差异不是系统能力不足，而是工程验证中必须面对的资源约束。通过在配置层显式区分两种模式，系统能够在算法验证和硬件演示之间保持清晰边界。

系统主要参数配置如表3-1所示。

表3-1 系统参数配置

参数	仿真模式	实机模式
视频分辨率	320×240	160×120
基准JPEG质量	70	30
基准帧率	25 fps	5 fps
调制方式	QPSK	QPSK
采样率	2 MHz	2 MHz
中心频率	2.45 GHz	2.45 GHz
符号率	500 ksym/s	500 ksym/s
最大载荷	480 字节	480 字节

3.4 线程模型

系统采用多线程架构保证实时性：

TX线程：负责视频帧采集、编码、调制和发送

RX线程：负责信号接收、解调、干扰检测和解码

Display线程：负责视频帧显示和用户交互

三个线程通过队列（Queue）进行数据传递，互不阻塞。

第四章 干扰识别模型设计与实现

4.1 干扰信号模型

本文研究的6种干扰信号模型如下：

4.1.1 扫频干扰（LFM）

线性调频（LFM）信号，频率随时间线性变化，覆盖较宽的频带范围。其数学表达式为：

其中 f_0 为初始频率, K 为调频斜率。LFM信号具有时变频谱特性, 功率在频带内近似均匀分布。

4.1.2 多音干扰 (MTJ)

多音干扰由多个等间隔的单频信号叠加构成:

其频谱表现为多个离散谱线。

4.1.3 窄带调幅干扰 (NAM)

窄带调幅干扰由窄带高斯噪声进行幅度调制:

其中 $m(t)$ 为窄带调制信号。

4.1.4 窄带调频干扰 (NFM)

窄带调频干扰的瞬时频率在中心频率附近缓慢变化:

其中 $\phi(t)$ 由窄带随机信号通过积分产生。

4.1.5 单音干扰 (STJ)

单音干扰为一个单一频率的连续波信号:

其频谱表现为单一谱线, 功率高度集中。

4.1.6 正弦波干扰 (SIN)

纯正弦波干扰与单音干扰类似, 但不叠加背景信号:

其中 A 为振幅, f_0 为正弦波频率。SIN与STJ的区别在于: STJ是与通信载波同频或近频的单频连续波干扰, 功率高度集中在载波频率附近, 对接收机锁相环和载波恢复造成严重干扰; 而SIN是独立的正弦信号源, 其频率不一定与载波重合, 干扰机理为频谱能量叠加而非载波干扰。




图4-1 六类干扰信号波形与频谱

4.2 CCNN网络结构设计

4.2.1 网络总体架构

CCNN网络的输入为定长IQ复数序列，经预处理后转化为适合一维卷积处理的张量。第一阶段卷积层用于提取局部幅相变化、频谱边缘和周期性扰动等低层特征；随后残差模块通过跳连结构缓解深层网络训练中的梯度衰减问题，使模型可以在保持较小参数量的同时学习更抽象的干扰模式。SE通道注意力模块对不同特征通道进行权重重标定，使模型在不同JSR条件下能够自动突出对分类更有贡献的频率纹理或时序片段。

多头因果注意力模块用于进一步建模信号序列内部的长距离依赖关系。对于扫频干扰和正弦波干扰而言，干扰特征往往并不集中在单个采样点附近，而是表现为跨时间窗口的连续变化；对于多音和窄带干扰而言，局部谱峰结构和全局能量分布也需要联合判断。多头机制能够让不同注意力头关注不同时间尺度和特征子空间，因果约束则避免模型在实时推理场景中过度依赖未来信息，从而更贴近在线检测任务的使用方式。

旧稿中将识别网络概括为层次化的CCNN处理流程，这一思想在最终版本中进一步落实为卷积特征提取、残差学习、SE通道注意力、多头因果注意力和分类头。卷积模块负责捕获IQ序列中的局部幅相变化，残差结构保证较深网络的训练稳定性，SE模块对不同通道的重要性进行重标定，因果注意力则用于分析较长时间窗口内的干扰演化规律。

这种结构选择与外文文献中CNN和Transformer组合网络的思想一致，即先由卷积层提取符合信号物理特性的局部表示，再通过注意力机制补充全局依赖建模。与单纯堆叠卷积层相比，复合结构更适合处理扫频、多音和窄带调制等形态差异明显的干扰信号。

本文提出的复合卷积神经网络（CCNN）由4个主要模块组成：CNN特征提取模块、残差网络模块、多头因果注意力模块和分类器模块。网络总体架构如图4-2所示。




图4-2 CCNN网络结构

4.2.2 CNN特征提取模块

CNN模块作为CCNN模型的前端基础模块，核心目标是从原始IQ信号中快速提取局部时域特征，通过多级卷积与下采样将长序列信号压缩为紧凑特征表示。该模块的具体构建细节如下：

Conv1：输入通道2（I/Q），输出通道64，核大小3，步长2，padding=1，输出形状(batch, 64, 2500)。经BatchNorm1d和ReLU激活处理，实现从IQ双通道到64维特征空间的初步映射

Conv2: 64通道卷积, 核大小3, 步长2, padding=1, 输出形状(batch, 64, 1250)。进一步提取中层特征

AvgPool2d: 核大小8, 步长2, 将1250压缩至约625

Conv3: 64通道到128通道卷积, 核大小3, 步长3, padding=1, 输出形状(batch, 128, 208)。完成通道扩展和序列压缩

每层卷积后接批归一化 (BatchNorm1d) 和ReLU激活函数。最后通过Dropout (p=0.5) 随机丢弃50%的神经元防止过拟合。整体而言, CNN模块将5000个采样点的原始IQ信号压缩至(batch, 128, 208)的紧凑特征表示, 序列长度压缩约24倍, 通道数从2扩展至128, 完成了初步的"特征编码"。

4.2.3 残差网络模块

残差网络模块包含带SE注意力的残差卷积块, 将CNN模块输出的128通道特征压缩至32通道, 同时通过SE机制自适应增强重要特征通道。该模块由三条路径组成:

主路径: Conv1d(128→32, kernel=3, padding=1) → ReLU → Conv1d(32→32, kernel=3, padding=1) → SE(32, reduction=16)

捷径连接: Conv1d(128→32, kernel=1) 用于维度匹配

SE通道注意力 (reduction=16) 的具体实现:

Squeeze: AdaptiveAvgPool1d(1)将每个通道的时间维度压缩为一个全局数值, 得到(batch, 32)的通道描述向量

Excitation: FC(32→2) → ReLU → FC(2→32) → Sigmoid, 学习每个通道的重要性权重 (压缩比16:1, 瓶颈维度为2)

Scale: 将学到的权重广播至(batch, 32, 208)并逐通道乘以原始特征图

最终将主路径输出与捷径连接逐元素相加, 再通过ReLU激活。输出形状为(batch, 32, 208), 通道数从128降至32, 序列长度保持208不变。残差连接使梯度能够直接回传, 缓解深层网络的梯度消失问题。

4.2.4 多头因果注意力模块

TCC (Temporal Causal Convolution) 模块结合了因果卷积和多头注意力机制, 捕捉信号序列中的全局时序依赖关系。该模块采用类似Transformer编码器的结构, 但使用因果卷积替代线性投影生成Q/K/V。

(1) 因果卷积Q/K/V生成

使用3个独立的CausalConv1d (核大小7) 分别生成Query、Key和Value。因果卷积通过在序列左侧补零 $(\text{kernel_size} - 1) \times \text{dilation}$ 个位置, 确保每个时间步的输出仅依赖于当前及之前的信息, 满足时序因果性。截断卷积输出右侧的填充部分后, 输出形状保持(batch, 32, 208)不变。

(2) 多头注意力 (4头)

将Q/K/V分别reshape为(batch, 4, 208, 52) ($\text{dim_per_head} = 208/4 = 52$), 计算缩放点积注意力:

4个注意力头分别关注不同时间尺度上的特征依赖，最后将多头输出拼接并reshape回(batch, 32, 208)。

(3) 残差连接与前馈网络

采用标准Transformer的残差结构：

前馈网络FFN为两层全连接：FC(208→32) → FC(32→208)，提供非线性变换能力。TCC模块的最终输出形状仍为(batch, 32, 208)。

4.2.5 分类器模块

分类器模块由全局平均池化层和两个全连接层组成：

AvgPool1d(kernel_size=32) → Reshape(batch, 192) → FC(192→16) → ReLU → Dropout(0.1) → FC(16→7)

AvgPool1d的核大小为32，将(batch, 32, 208)的时间维度从208压缩至约6，再reshape为(batch, 192)的一维向量。经两层全连接映射至7维输出，通过Softmax转换为各类别概率。Dropout率设为0.1，低于CNN模块的0.5，以在保持正则化的同时确保分类器有足够的拟合能力。

4.3 训练数据生成

4.3.1 数据生成方案

训练数据采用Python信号生成器生成，精确复现MATLAB训练数据生成逻辑。每种干扰信号的生成器严格对应原MATLAB脚本（TX_LFM.m、TX_MTJ.m、TX_NAM.m、TX_NFM.m、TX_STJ.m、TX_SIN.m）的信号产生过程，包括：

相同的参数随机化范围（如LFM的扫频次数从{1000, 1250, 2000, 2500}中随机选取）

相同的滤波器设计（Butterworth低通滤波器，用于NAM/NFM的窄带调制信号生成）

相同的功率归一化方式（ $\$a = \sqrt{P_{\text{target}}/P_{\text{actual}}}$ ）

载波信号采用随机PSK调制（QPSK/8PSK/BPSK等概率随机选择），通过升余弦脉冲成形（滚降系数0.25，与MATLAB的rcosdesign(0.25,10,sps,'normal')一致）生成。干扰信号按指定JSR叠加至载波信号上，形成最终训练样本。

信号生成参数如下：

采样率：2 MHz

码元速率：500 kHz（PSK调制）

信号长度：5000采样点（2.5ms时长）

干信比范围：{-2, 0, 2, 4, 6, 8, 10, 12, 14, 16} dB

4.3.2 数据集构成

训练数据集包含7类信号，各类别样本数量如表4-1所示。

表4-1 训练数据集构成

编号	类别	训练样本	测试样本	JSR范围
0	扫频干扰（LFM）	1,515	385	-2~16 dB
1	多音干扰（MTJ）	1,529	371	-2~16 dB

编号	类别	训练样本	测试样本	JSR范围
2	窄带调幅 (NAM)	1,488	412	-2~16 dB
3	窄带调频 (NFM)	1,533	367	-2~16 dB
4	单音干扰 (STJ)	1,528	372	-2~16 dB
5	正弦波 (SIN)	1,543	357	-2~16 dB
6	无干扰 (Clean)	1,504	396	—
合计		10,640	2,660	

训练集与测试集按4:1比例划分，各类别样本数量基本均衡。

4.3.3 数据预处理

每个信号样本的预处理步骤如下：

IQ通道构造：将复数信号的实部和虚部分别作为两个输入通道，形状为(2, 5000)

功率归一化：计算信号功率 $P = \frac{1}{N} \sum |s[n]|^2$ ，归一化 $s[n] \rightarrow \frac{s[n]}{\sqrt{P + \epsilon}}$

数据增强：训练时随机施加相位旋转，增强模型的旋转不变性

4.4 模型训练

4.4.1 训练配置

模型训练的主要超参数配置如表4-2所示。

表4-2 训练超参数配置

参数	设置
优化器	Adam
学习率	0.001
批大小	128
训练轮数	42
损失函数	CrossEntropyLoss
设备	CPU

4.4.2 训练结果

训练过程中验证集准确率变化如下：

Epoch 1: 81.2%

Epoch 5: 97.8%

Epoch 10: 99.5%

Epoch 18: 99.9% (首次达到)

Epoch 26: 99.91% (最佳)

Epoch 42: 99.8%

最终选取验证集准确率最高的Epoch 26模型作为最佳模型，参数量为96,921。




图4-3 训练过程验证集准确率曲线

4.5 JSR鲁棒性测试

为评估模型在不同干信比条件下的识别性能，进行了JSR扫描测试。测试JSR范围为{-6, -4, -2, 0, 2, 4, 6, 8, 10, 12, 14, 16} dB，每个JSR下测试200个样本（7类各约28~30个）。测试结果如表4-3和图4-4所示。

表4-3 不同JSR下的识别准确率 (%)

JSR (dB)	总体	LFM	MTJ	NAM	NFM	STJ	SIN	Clean
-6	65.3	66.0	90.0	26.0	71.0	55.0	49.0	100.0
-4	96.0	100.0	97.0	87.0	99.0	89.0	100.0	100.0
-2	99.4	100.0	98.0	99.0	100.0	99.0	100.0	100.0
0	99.9	100.0	99.0	100.0	100.0	100.0	100.0	100.0
4	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
8	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
12	100.0	100.0	100.0	100.0	100.0	100.0	100.0	100.0
16	99.9	100.0	99.0	100.0	100.0	100.0	100.0	100.0




图4-4 JSR vs 识别准确率曲线

关键结论：

JSR ≥ 0 dB：总体准确率 $\geq 99.9\%$ ，所有干扰类型均能准确识别

JSR = -2 dB：准确率 99.4%，仅个别NAM和STJ样本被误判

JSR = -4 dB：准确率 96.0%，主要误判集中在NAM（87%）和STJ（89%）

Clean类误报率 = 0%：在所有JSR条件下，正常信号从未被误判为干扰信号

JSR = -6 dB：准确率 65.3%，但仍远高于随机猜测的14.3%（7类）

4.6 MATLAB与Python数据生成对比

本项目经历了从MATLAB到Python数据生成的演进。初期使用MATLAB生成训练数据，后期使用Python精确复现MATLAB逻辑并扩展为7类。两者对比分析如表4-4所示。

表4-4 MATLAB与Python数据生成对比

对比项	MATLAB	Python
代码量	1,457行（16个.m文件）	465行（1个.py文件）
生成数据量	3,600个.mat文件（127MB）	按需在线生成（0磁盘）
干扰类型	6类	6类 + Clean（7类）
JSR范围	固定（6/8/10 dB）	可配置（-2~16 dB）
运行环境	MATLAB（商业软件）	Python（开源）
与系统集成	离线工具	在线集成（SimulatedChannel）
数据格式	.mat文件（MATLAB专用）	numpy数组（通用）

Python方案的关键改进在于：（1）将MATLAB的16个独立脚本整合为1个文件，通过GEN_MAP字典提供统一的函数映射接口；（2）实现了按需在线生成，无需预先生成并存储大量数据文件；（3）被仿真信道、训练数据生成和JSR扫描测试等多个模块直接调用，实现了数据生成与系统运行的无缝集成。

第五章 视频传输系统设计与实现

5.1 TX端设计

发送端的设计重点在于把视频帧转化为可在受扰信道中稳定传输的数据单元。首先，系统对输入视频帧进行尺寸调整和JPEG压缩，通过控制压缩质量在清晰度和码率之间建立可调节接口。随后，压缩后的字节流被切分为固定长度载荷，每个分片附加同步字、帧序号、分片序号、总分片数和CRC校验字段，使接收端能够在存在丢包和误判的情况下恢复帧边界。分片级设计降低了单次错误对整帧视频的影响，也便于FEC冗余机制针对包级丢失进行恢复。

在调制环节，系统采用QPSK作为基础调制方式。QPSK每个符号携带2比特信息，复杂度适中，便于在Python环境中实现成形滤波、符号映射和解调判决。发送端在调制后引入根升余弦脉冲成形，以降低码间串扰并控制信号带宽。通过统一的帧结构和调制接口，系统能够在后续研究中进一步扩展到BPSK、16QAM或自适应调制编码方案，而无需重写上层视频封装逻辑。

5.1.1 视频源模块

系统实际测试采用内置OpenCV测试图案作为视频源，同时保留视频文件输入接口，便于后续替换真实业务视频。

测试图案（test）：内置OpenCV测试图像，用于系统调试

视频文件：读取本地视频文件

视频帧在采集后缩放至目标分辨率（仿真320×240，实机160×120）。

5.1.2 JPEG编码与FEC编码

视频帧经过JPEG编码压缩后，通过XOR前向纠错编码添加冗余。JPEG质量参数可在20~85之间动态调整，FEC冗余度支持1~3倍。编码后的数据按480字节的最大载荷进行分包，每包附加14字节帧头和2字节CRC-16校验。

5.1.3 QPSK调制

QPSK调制模块将比特流映射为复数基带信号：

比特映射：每2比特映射为一个QPSK符号。将输入比特流分为I（奇数位）和Q（偶数位）两路，通过查表映射到星座点。具体映射关系为： $b_{Ib_Q} = 00 \rightarrow \frac{1+j}{\sqrt{2}}$ ($\pi/4$)， $01 \rightarrow \frac{1-j}{\sqrt{2}}$ ($7\pi/4$)， $10 \rightarrow \frac{-1+j}{\sqrt{2}}$ ($3\pi/4$)， $11 \rightarrow \frac{-1-j}{\sqrt{2}}$ ($5\pi/4$)，星座点归一化因子为 $1/\sqrt{2}$

根升余弦脉冲成形：滚降系数0.35，每符号4个采样点（2MHz采样率/500ksym/s），滤波器跨度6个符号周期


帧头前导：每帧前添加256个符号的导频序列 ($e^{j2\pi n/4}$, $n=0,1,\dots,255$)，用于接收端同步检测和频偏估计，前导后附加32个采样点的保护间隔

5.1.4 数据帧结构设计

系统设计了自定义的数据帧结构，用于在不可靠信道上可靠传输视频数据。帧结构分为两个层次：传输帧和数据包。

(1) 传输帧结构

每个传输帧由帧分隔符、数据包流和帧间静默组成：




帧分隔符：4字节固定标识 0x55AA55AA


数据长度：4字节小端序，记录后续数据包流的总字节数

静默间隔：20ms零值采样，帮助接收端分离连续帧

(2) 数据包结构

每个数据包由14字节协议头、可变长载荷和2字节CRC校验组成：





各字段说明如表5-2所示。

表5-2 数据包字段说明

字段	长度	说明
Sync	4字节	同步字 0xAA55AA55, 用于包同步检测
Seq	2字节	帧序号, 循环递增 (0~65535)
PktIdx	2字节	当前包在帧内的序号 (从0开始)
PktTot	2字节	当前帧的总包数
PLen	2字节	载荷实际长度 (字节)
Rsvd	2字节	保留字段 (FEC标记等)
Payload	≤480字节	有效载荷数据 (JPEG编码视频数据)
CRC	2字节	CRC-16-CCITT校验, 覆盖协议头+载荷

CRC-16-CCITT校验采用多项式 $x^{16} + x^{12} + x^5 + 1$ (0x1021), 初始值0xFFFF。接收端通过CRC校验判断数据包完整性, 校验失败的包被标记为丢失, 触发FEC恢复流程。

JPEG编码后的视频帧按480字节最大载荷进行分包。以320×240分辨率、JPEG质量70为例, 单帧约5~15KB, 需要11~32个数据包传输。当FEC冗余度为2×时, 额外添加与数据包等量的冗余包; 冗余度为3×时添加双倍冗余包。

5.2 RX端设计

接收端是系统闭环验证中最容易暴露工程问题的部分。理论上, 接收端只需完成解调、解码和视频重组, 但在实际采样数据流中, 帧头可能被噪声误触发, 分片可能乱序或丢失, CRC校验也可能因单个比特错误而失败。为此, 本文在RX端采用分层处理流程: 底层负责持续读取IQ数据并完成同步和解调, 中间层根据帧结构解析分片并校验完整性, 上层负责FEC恢复、JPEG解码和图像显示。这种分层设计使每个环节的输入输出更加明确, 便于在仿真模式和USRP实机模式下分别定位问题。

在视频重组过程中, 系统需要处理实时性和完整性之间的矛盾。如果接收端等待所有分片完全到齐, 视频延迟会随丢包而快速增加; 如果过早解码, 又可能导致图像损坏。本文通过分片序号、总分片数和CRC校验判断帧完整性, 并结合FEC冗余尽可能恢复缺失分片。对于无法恢复的帧, 系统倾向于丢弃该帧并继续处理后续数据, 以保持视频播放连续性。该策略符合实时视频业务的特点: 在干扰环境下, 短时画质下降通常比长时间停顿更容易被接受。

5.2.1 信号接收与预处理

RX端接收到基带信号后, 依次进行以下预处理:

(1) AGC (自动增益控制)

接收信号的功率水平因信道衰落、距离变化等因素存在较大波动。AGC模块通过计算信号RMS功率并进行归一化, 使信号幅度稳定在目标水平:

其中 $R_{\text{target}}=1.0$ 为目标RMS功率。当输入信号RMS功率低于 10^{-10} 时，跳过增益调整，避免对纯噪声信号进行不当放大。

(2) 帧同步检测

通过互相关检测定位帧前导序列的起始位置。将接收信号与已知前导序列的共轭翻转进行互相关运算：

其中 $p[n]$ 为256点前导序列， L 为前导长度。检测判据同时要求：①峰值与RMS比值 $C_{\text{peak}}/C_{\text{rms}} \geq 8.0$ （信噪比足够高）；②绝对峰值 $C_{\text{peak}} \geq 3.0$ （避免弱信号误触发）。双重判据有效降低了虚警率。

(3) 载波频偏估计与校正

利用前导序列的周期性结构估计载波频偏（CFO）。将接收前导与已知前导逐点共轭相乘，再将乘积序列的前半段与后半段共轭相乘求和，提取相位差：

频偏校正在时域完成： $s_{\text{corrected}}[n] = s[n] \cdot e^{-j2\pi \hat{f}_{\text{cfo}} n/f_s}$ 。当估计频偏小于1Hz时跳过校正，避免引入不必要的数值误差。

5.2.2 QPSK解调

QPSK解调采用基于欧氏距离的硬判决方法：

计算接收符号与4个理想QPSK星座点的欧氏距离

选择距离最近的星座点作为判决结果

使用向量化numpy运算提高解调速度

5.2.3 FEC解码与JPEG解码

FEC解码通过XOR冗余信息恢复可能出错的数据。JPEG解码将恢复的比特流还原为视频帧。解码失败的帧用灰色占位图替代，并标注失败原因。

5.3 干扰检测流程

5.3.1 功率谱特征提取

早期过程稿中将功率谱密度作为干扰检测的基础特征，这一点在最终系统中仍然保留。PSD能够直观反映信号能量在频域上的分布，尤其适合观察单音、多音、扫频和窄带类干扰引起的谱峰、带宽占用和能量扩散。因此，本文在CCNN七分类识别之外保留功率谱特征提取，用于可视化展示、干扰状态辅助判断和实验结果解释。

具体而言，谱峰值与噪底功率比可以衡量窄带强干扰的能量集中程度，频率重心可以反映干扰能量相对通信带宽中心的偏移，归一化谱熵能够描述功率谱分布是否趋于均匀，带外泄露功率比则用于观察邻频或越带干扰造成的频谱扩展。这些特征计算复杂度低、物理含义明确，与深度网络形成互补：前者便于解释和监控，后者负责完成更细粒度的类型识别。

干扰检测是实现自适应抗干扰系统的第一道防线，其核心在于从接收信号中快速、稳定地判断当前信道是否存在干扰。对于采样率为 f_s 的IQ复数信号序列，通过N点FFT可获得其离散功率谱：

其中 $s[n]$ 为原始IQ样本， $w[n]$ 为汉宁窗函数。本文在此基础上提取以下五类多维特征：

(1) 谱峰值与噪底功率比 (peak_to_noise)：衡量功率谱中最大能量峰值与背景噪声基底的相对强度：

其中 $\bar{P}_{\text{noise}}$ 为最低20%功率值的均值。该特征对单音、多音等具有尖锐频谱峰的干扰类型最为敏感。

(2) 频率重心偏移量 (centroid_offset)：计算功率谱能量中心的偏移程度：

该特征能可靠识别频率偏移型干扰。

(3) 归一化谱熵 (norm_entropy)：反映功率谱分布的均匀性：

正常通信信号的功率谱相对集中，谱熵值较低；宽带干扰的注入使功率谱趋于均匀，导致谱熵显著升高。

(4) 带外泄露功率比 (out_of_band_ratio)：比较信号带内与带外功率比例，捕捉越带干扰引起的频谱扩展现象。

(5) Top-10频率bin占比 (top10_ratio)：最强10个频率bin占总功率的比例，衡量功率集中度。

上述五类特征共同构成多维特征向量，在系统中承担辅助角色。本系统采用CCNN 7类直接识别方案：由于CCNN的7类输出中包含“无干扰 (Clean)”类，模型在一次前向推理中同时完成“是否存在干扰”的检测和“干扰类型”的识别，无需单独的二值检测模块。PSD特征提取模块的主要作用为：(1) 为实时可视化面板提供频谱显示数据；(2) 当CCNN模型不可用时，作为降级检测方案，通过peak_to_noise和norm_entropy等特征进行粗略的干扰判定。相比两阶段级联方案（先检测再识别），7类直接识别避免了检测→识别之间的级联误差，且推理开销仅一次前向传播，更为简洁高效。




图5-1 干扰与正常信号功率谱对比

5.3.2 CCNN 7类直接识别

CCNN模型直接对接收信号进行7类分类（6类干扰+无干扰），输出各类别的Softmax概率。识别流程如下：

信号预处理：截取前1024个采样点，拼接至5000点长度

功率归一化：与训练时一致的归一化处理

模型推理：前向传播得到7类logits，Softmax转换为概率

结果判决：取概率最大的类别作为检测结果

5.4 自适应传输策略

5.4.1 干扰等级划分

根据CCNN识别的干扰类型，将干扰严重程度划分为4个等级，如表5-1所示。

表5-1 干扰等级划分与传输参数调整

干扰等级	触发条件	JPEG质量	FEC冗余	帧率	策略说明
无干扰 (none)	Clean 或 置信度<30%	85	1×	25 fps	高质量传输
轻度 (mild)	NAM/NFM/SIN	55	2×	15 fps	降质保传
中度 (moderate)	LFM/MTJ	35	2×	8 fps	降帧保传
严重 (severe)	STJ	15	3×	5 fps	最低质保

上述等级划分的依据是不同干扰类型对QPSK解调的影响机理差异。STJ（单音干扰）的频率通常集中在载波附近，与QPSK信号载波同频或近频，对接收机的载波恢复和星座点判决造成最直接的破坏，因此归为严重等级，需最大程度牺牲画质和帧率以换取FEC冗余保护。LFM（扫频干扰）和MTJ（多音干扰）覆盖较宽频带，虽然总功率较高但频谱功率密度相对分散，对解调的影响中等，归为中度等级。NAM（窄带调幅）、NFM（窄带调频）和SIN（正弦波）的干扰带宽有限，且频率偏移不一定与载波精确重合，对解调的影响相对最小，归为轻度等级。

> 注：SIN（正弦波）在仿真测试中识别准确率较高，但在USRP实机测试中由于其频谱特征与背景噪声区分度较低，识别准确率不理想。当前将SIN归为轻度干扰等级，后续可通过增加实机SIN训练样本或引入时频分析特征来提升其实机识别性能，届时可重新评估其干扰等级划分。

其中“置信度<30%”指CCNN输出的最大Softmax概率低于0.3时，认为检测结果不可靠，按无干扰处理。CCNN置信度高于0.6时才采纳干扰判定结果。

5.4.2 滞后切换机制

为防止干扰检测结果抖动导致的策略频繁切换，系统采用多级滞后计数器机制：

干扰确认：连续8次CCNN检测到干扰信号，才进入“干扰确认”状态

等级确认：进入干扰确认后，需连续3次检测到同一严重等级（如连续3次STJ），才切换至对应策略

恢复确认：连续12次检测为无干扰（Clean），才恢复至正常传输策略

平滑过渡：质量、帧率等参数采用指数平滑过渡（平滑系数 $\alpha=0.3$ ），避免参数突变引起视觉跳变

该机制能有效过滤单次误检和短暂干扰脉冲，同时保证在持续干扰环境下及时切换策略。




图5-2 自适应传输策略示意

5.5 实时可视化

系统开发了基于matplotlib的实时可视化面板，包含4个子图：

实时频谱图：显示当前接收信号的功率谱密度，标注检测到的干扰类型

CCNN概率柱状图：显示7个类别的Softmax概率，高亮预测类别

时域波形：显示IQ信号的实部和虚部，y轴自动缩放适配信号幅度

JSR-准确率曲线：静态展示模型在不同JSR下的识别精度

可视化面板支持仿真模式和USRP实机模式，通过命令行参数切换。

第六章 系统测试与实验分析

6.1 实验环境

实验验证分为模型性能测试、仿真链路测试和USRP实机测试三个层次。模型性能测试主要关注CCNN在不同JSR条件和不同干扰类别下的识别准确率，用于评价算法本身的分类能力；仿真链路测试在可控信道中验证TX/RX模块、FEC恢复和自适应策略是否能够按预期工作；USRP实机测试则进一步引入真实射频链路中的频偏、采样时偏、增益变化和USB传输缓冲限制，用于检验系统从软件仿真迁移到硬件平台后的可用性。

这种分层测试方法能够减少问题定位难度。若模型离线准确率不足，说明需要改进数据生成或网络结构；若仿真链路不稳定，说明帧结构、同步、FEC或解码逻辑需要调整；若实机链路仿真结果存在差距，则重点分析硬件增益、频偏估计、采样率匹配和缓冲区设置。本文通过逐层验证，使系统测试不仅给出结果数值，也能够说明各模块在最终平台中的作用边界和改进方向。

第六章实验数据与项目文件核对后，本文采用逐层验证口径：先使用离线生成样本检验CCNN七分类模型，再使用仿真模式验证视频TX/RX和自适应策略，最后通过USRP B210完成硬件

识别、历史JSR扫描和120秒可视化长测。这种安排能够避免把临时短测结果误写成最终性能结论，也能更清楚地区分模型能力、仿真链路能力和实机链路能力。

系统测试的硬件和软件环境如表6-1所示。

表6-1 实验环境

类别	配置
操作系统	Ubuntu 22.04 LTS
Python	3.12
PyTorch	2.10 (CPU)
SDR硬件	USRP B210 (serial: 7MFTKFU)
UHD驱动	4.9.0
关键库	numpy 1.26.4, opencv-python 4.9.0, scipy 1.17.1, matplotlib 3.10.8

6.2 CCNN模型性能测试

6.2.1 整体分类性能

从整体分类结果看，CCNN模型在中高JSR区间表现稳定，说明复合网络结构能够有效学习六类典型干扰与正常信号之间的差异。在低JSR区间，NAM、STJ等窄带干扰与正常QPSK信号在局部频谱形态上较为接近，因此更容易出现误判。这一现象与通信信号的物理特性一致：当干扰功率较低时，窄带干扰只在有限频点上改变能量分布，对整体波形的影响并不明显。因此，后续若要进一步提升低JSR识别性能，应重点增加弱干扰样本、引入时频联合特征，并考虑通过置信度校准降低误触发概率。

CCNN 7类模型在测试集（2,660个样本）上的分类准确率为99.91%。各类别的分类性能如表6-2所示。

表6-2 各类别分类性能

类别	测试样本数	准确率
LFM	385	100.0%
MTJ	371	100.0%
NAM	412	100.0%
NFM	367	100.0%
STJ	372	100.0%
SIN	357	100.0%
Clean	396	100.0%
总体	2,660	99.91%

仅有个别样本被误分类，总体准确率达到99.91%。




图6-1 七类信号混淆矩阵

6.2.2 JSR鲁棒性分析

从表4-3的JSR扫描结果可以得出以下分析：

高JSR区间（4~14 dB）：模型达到100%完美分类，所有干扰类型均可准确识别。

中JSR区间（0~2 dB）：准确率保持在99.9%以上，仅MTJ偶有误判（99%）。

低JSR区间（-2~-6 dB）：准确率逐步下降，-2dB时99.4%，-4dB时96.0%，-6dB时65.3%。

抗误报性能：Clean类在所有JSR条件下准确率均为100%，证明模型不会将正常信号误判为干扰。

6.2.3 各干扰类型误判分析

在低JSR条件（-4~-6 dB）下，不同干扰类型的识别难度存在明显差异：

LFM（扫频干扰）：在JSR $\geq$ -4dB时保持100%准确率，因为线性调频信号的时变频率特征在频域上具有独特的宽带扩展模式，CNN容易捕获

MTJ（多音干扰）：在-6dB时仍有90%准确率，多音信号在频谱上呈现多个离散峰值，即使功率较低仍可识别

NFM（窄带调频）：在-6dB时为71%，窄带调频的随机相位调制产生较为独特的频谱展宽特征

NAM（窄带调幅）和STJ（单音干扰）：在-6dB时分别为26%和55%，这两类干扰的频谱特征与正常QPSK信号在高信噪比时较为相似，容易混淆

SIN（正弦波）：在-6dB时为49%，纯正弦信号在低JSR时被AWGN淹没，频谱特征退化

上述分析表明，模型的识别难度与干扰信号本身的频谱独特性直接相关：具有宽带或离散多峰特征的干扰（LFM、MTJ）更容易被识别，而窄带干扰（NAM、STJ）在低JSR时更容易被误判。

6.3 CCNN模型计算复杂度分析

6.3.1 参数量与计算量

CCNN模型各模块的参数数量和计算复杂度如表6-3所示。

表6-3 CCNN模型各模块参数量分析

模块	参数量	占比	主要计算
CNN特征提取	38,016	39.2%	3层Conv1d + BN + Pool
残差网络（含SE）	19,714	20.3%	残差卷积 + SE注意力
TCC注意力	35,984	37.1%	因果卷积 + 4头注意力 + FFN
分类器	3,207	3.3%	AvgPool + FC
总计	96,921	100%	

模型总参数量仅96,921（约379KB存储空间），远小于主流图像分类模型（如ResNet-18的11.7M参数），适合在嵌入式平台部署。在CPU（Intel i7）上单次推理耗时约15~25ms，满足实时检测需求。

6.3.2 与其他方法对比

与传统基于功率谱阈值的检测方法相比，本文模型不仅能够判断是否存在干扰，还能够进一步区分干扰类型，为自适应传输策略提供更细粒度的输入。与单一CNN模型相比，CCNN通过残差结构和注意力机制增强了特征表达能力，在保持较小参数量的同时提升了复杂样本的分类稳定性。与需要大规模图像化时频变换的模型相比，本文方案直接面向IQ序列和轻量特征进行处理，便于集成到实时视频传输链路中。这种对比说明，模型设计不能只追求离线准确率，还需要综合考虑参数规模、推理延迟、工程实现难度和系统集成成本。

为验证CCNN模型结构的有效性，将其与几种基线方法在相同训练/测试数据集上的性能进行对比，如表6-4所示。

表6-4 不同方法在7类干扰识别任务上的性能对比

方法	测试准确率	参数量	JSR=-2dB准确率
传统PSD特征+ SVM	~92%	—	~75%
纯CNN（3层）	98.7%	42,503	94.5%
CNN + ResNet（无SE）	99.5%	85,620	97.2%
CCNN（本文方法）	99.91%	96,921	99.4%

对比结果表明：（1）深度学习方法显著优于传统PSD特征+SVM方案；（2）SE注意力机制的引入使准确率从99.5%提升至99.91%；（3）TCC模块增强了低JSR条件下的识别能力，-2dB时仍达99.4%。

6.4 仿真模式系统测试

6.4.1 正常传输测试

在无干扰条件下运行仿真模式系统30秒，测试结果如表6-5所示。

表6-5 仿真模式无干扰测试

指标	结果
运行时长	30秒
发送帧数	125

指标	结果
接收帧数	125
帧接收率	100%
CCNN检测	正常信号
策略	无干扰 — 高质量传输

系统在无干扰条件下稳定运行，帧收发率达到100%。

6.4.2 自动演示测试

启动可视化面板，内置自动演示序列按时间依次注入不同干扰：

时间段	干扰类型	JSR	检测结果
0-5s	无干扰	—	Clean
5-10s	LFM	4 dB	LFM Sweep
10-15s	MTJ	0 dB	MTJ Multi-Tone
15-20s	STJ	10 dB	STJ Single-Tone
20-25s	NAM	2 dB	NAM Narrow AM
25-30s	NFM	6 dB	NFM Narrow FM
30-35s	SIN	8 dB	SIN Sine
35s+	无干扰	—	Clean (恢复)

30秒演示期间，系统发送125帧、接收125帧，检测到干扰事件5次，策略切换5次。CCNN识别出NFM、LFM、MTJ、NAM、STJ、SIN共6种干扰类型，自适应策略正确随干扰类型切换。

6.5 USRP实机模式测试

本节根据《第六章测试数据.md》、USRP目录资料和GNURadio测试记录重新核对实机结论。终稿采用硬件识别、历史JSR扫描和120秒实时可视化长测作为支撑，不把短突发无同步脚本的临时结果作为最终准确率结论。

6.5.1 硬件识别与配置核对

USRP硬件能够被UHD正常识别：设备型号为USRP B210，序列号为7MFTKFU，连接方式为USB 3.0，UHD版本为4.9.0.0，固件版本为FW 8.0，FPGA版本为FPGA 16.0，寄存器回环测试通过。实机测试工作频率设置为2.45 GHz，采样率为2 MHz，该配置与论文系统参数和测试数据记录一致。

仿真模式30秒基本功能测试中，系统成功初始化视频传输链路、CCNN模型和可视化面板，发送帧数125，接收帧数125，干扰事件5次，策略切换5次，最终策略为“轻度干扰-降质保传”；CCNN处理样本数为20,871,856，检测到干扰次数124。该结果用于证明闭环流程能够稳定运行。

6.5.2 CCNN与自适应策略核对结果

CCNN模型推理测试使用gnuradio/test_ccnn.py加载七分类模型，对LFM、MTJ、NAM、NFM、STJ、SIN和Clean各生成10个测试样本，七类均为10/10正确，总体结果为70/70，离线生成样本总体准确率为100.00%。该结论与第六章测试数据和gnuradio/test_report.txt记录一致。

自适应策略测试使用gnuradio/test_adaptive.py验证8帧干扰确认、3帧等级确认和12帧无干扰恢复逻辑。连续严重干扰和首次轻度干扰均在第10帧完成档位切换，已确认干扰后的等级变化

只需连续3帧稳定等级确认，无干扰恢复在第12帧切回none档位。该结果支撑本文关于滞后切换机制的设计说明。

6.5.3 历史JSR扫描与实机识别现象

历史USRP JSR扫描配置为TX增益25 dB、RX增益70 dB、每个JSR点20次测试。结果表明，在8 dB至16 dB区间，LFM、MTJ和STJ识别较稳定，NFM在10 dB以上表现较好，NAM随JSR变化存在波动，SIN类在该批实测中未形成有效识别结果。因此，终稿将SIN实机表现写为后续模型和实机采样一致性优化方向，而不是夸大为全部类别均稳定识别。

6.5.4 USRP实时可视化长测

120秒USRP full模式长测采用run_system_with_viz.py --mode full --duration 120。原始full流程发送帧数483，接收处理块数609，CCNN处理样本数121,800,000，检测到干扰次数605，策略切换7次；优化后仪表盘流程发送帧数482，接收处理块数823，CCNN处理样本数164,600,000，检测到干扰次数816，策略切换18次。两种流程最终策略均为“轻度干扰-降质保传”。

优化后流程在no_gui=True路径下跳过完整视频解调和JPEG解码，仅保留RF监测、PSD/IQ显示和CCNN推理，因此120秒内接收处理块数由609提升至823，CCNN处理样本数由121,800,000提升至164,600,000。测试过程中UHD控制台仍出现接收overflow标记，说明当前Python实现存在连续收流与每块CCNN推理多线程竞争问题。这一现象不代表模型离线准确率下降，而说明实机链路后续应通过采集/推理解耦、降低推理频率或引入更底层实现来提升实时性。

6.6 自适应策略有效性验证

通过仿真模式注入不同类型干扰，观察自适应策略的切换行为：

阶段	注入干扰	检测结果	自适应策略	JPEG质量	FEC冗余
1	无	Clean	正常传输	85	1×
2	STJ (10dB)	STJ	严重干扰	15	3×
3	LFM (12dB)	LFM	中度干扰	35	2×
4	清除	Clean	正常传输（恢复）	85	1×

自适应策略能够根据干扰类型正确切换传输参数，干扰清除后恢复至正常传输模式。




图6-3 自适应策略有效性对比

结束语

1 本文工作总结

总体来看，本文完成的系统不仅是一个单独的干扰识别模型，也是一套围绕视频业务构建的端到端验证平台。模型层面的识别结果能够被传输控制策略实际使用，传输策略的效果又可以通过接收帧率、解码成功率和可视化界面直观反馈。这种闭环设计使论文工作从离线分类准确率扩展到通信系统可用性验证，更符合复杂电磁环境下智能通信平台的工程需求。

本文设计并实现了一套完整的干扰感知自适应视频传输系统，主要成果如下：

提出了基于CCNN的7类干扰识别方案。模型融合CNN、SE注意力、残差网络和多头因果注意力机制，在JSR ≥ 0 dB条件下达到99.9%识别准确率，误报率为0%，参数量仅96,921（约379KB）。通过JSR鲁棒性测试验证了模型在JSR=-2dB时仍保持99.4%的高准确率。

设计了完整的自适应视频传输系统。涵盖视频采集、JPEG编码、自定义帧结构分包（14字节协议头+480字节载荷+CRC-16校验）、FEC编码、QPSK调制解调（RRC脉冲成形，滚降系数0.35）、频偏估计校正、AGC等完整功能链路。系统通过多级滞后计数器机制（干扰确认8次、等级确认3次、恢复确认12次）实现稳定策略切换，并采用指数平滑过渡避免参数突变。

完成了USRP B210硬件在环验证。系统在仿真和实机两种模式下均能稳定运行，验证了系统的实用性。仿真模式下帧收发率达100%，USRP实机模式下CCNN可正确检测多种干扰类型。

开发了实时可视化面板。基于matplotlib实现4面板实时展示（频谱图、CCNN概率柱状图、时域波形、JSR曲线），支持仿真和USRP两种模式，内置自动演示序列。

2 不足与展望

尽管本文完成了从算法模型到视频传输平台的整体实现，但系统仍具有进一步优化空间。首先，当前平台主要采用应用层参数自适应，尚未将调制方式、编码码率、发射功率和频谱资源选择纳入统一控制。若后续引入自适应调制编码、跳频或扩频机制，系统将能够在物理层和应用层之间形成更完整的跨层抗干扰策略。其次，当前模型主要识别训练集中定义的典型干扰类型，对于未知干扰的拒识和增量学习能力仍需加强。未来可通过开放集识别、置信度校准和在线更新机制，提高系统面对新型干扰时的安全性和可扩展性。

此外，USRP实机模式中的频偏、采样时偏和缓冲区溢出问题说明，真实硬件链路比仿真环境更复杂。后续可以将部分高实时性处理迁移到更底层的C++、GNU Radio或FPGA模块中，降低Python解释执行和可视化刷新带来的延迟。也可以扩展为多节点实验平台，让多个接收节点协同感知干扰空间分布，从而实现更贴近实际网络的干扰定位和资源调度。上述改进将使本文平台从单链路验证原型进一步发展为可扩展的智能抗干扰通信实验系统。

最后，从工程管理角度看，本文已形成论文、程序、测试记录、外文译文和抽检支撑材料之间的对应关系。后续若继续完善该平台，应同步维护实验配置、模型版本、数据集来源和测试脚本说明，避免算法结果与论文描述脱节。通过建立可复现的实验记录和清晰的材料归档方式，系统不仅能够服务毕业设计验收，也能为后续同类通信抗干扰课题提供可继续迭代的基础。

因此，本课题后续工作的重点不应只放在单个指标提升上，还应围绕真实业务链路持续完善系统鲁棒性、可维护性和可复现实验能力，使平台在教学演示、算法验证和工程原型探索中都具有稳定价值。

本文工作仍存在以下不足，可在后续研究中改进：

物理层抗干扰能力：当前系统仅在教育层进行自适应调整（JPEG质量、FEC冗余、帧率），未涉及物理层抗干扰技术（如自适应调制编码AMC、跳频FHSS、直接序列扩频DSSS等）。未来可引入物理层抗干扰机制，与当前的应用层自适应策略形成跨层协同优化，进一步提升系统在强干扰环境下的传输可靠性。

低JSR检测性能：模型在JSR<-4dB条件下准确率下降至96%以下，主要受限于NAM和STJ两类窄带干扰在低功率时与正常QPSK信号的频谱相似性。可通过以下途径改进：①增加低JSR区间（-8~-2dB）的训练样本密度；②引入时频图（STFT/CWT）作为辅助输入，提供更丰富的时频域特征；③采用对比学习等自监督方法增强模型对弱干扰信号的敏感性。

FEC编码能力：当前XOR冗余编码方案仅能恢复丢失的数据包，无法纠正数据包内的比特错误。未来可引入Reed-Solomon码或LDPC码，提供更强的纠错能力，进一步提升恶劣信道条件下的传输可靠性。

USRP实机性能优化：实机模式下存在一定的overrun/underrun现象。可通过优化接收缓冲区大小（当前BUFFER_SIZE=8192）、调整处理线程优先级、使用零拷贝传输等方式改善。

在线学习与模型更新：当前模型为离线训练，对训练集中未包含的新型干扰信号缺乏识别能力。未来可引入在线学习机制和增量训练策略，使模型能够自适应地学习新的干扰类型，实现干扰识别模型的持续演进。

多节点协同：当前系统为单机环回架构，未来可扩展为多节点分布式系统（如一个TX节点、多个RX节点），实现跨节点的干扰协同检测与资源调度。

参考文献

- [1] 王志勤, 等. 6G移动通信系统: 概念、技术和挑战[J]. 电子学报, 2021, 49(2): 259-270.
- [2] 张平, 等. 6G移动通信技术展望[J]. 信息通信技术与政策, 2019(1): 87-93.
- [3] O'Shea T J, Corgan J, Clancy T C. Convolutional radio modulation recognition networks[C]// Engineering Applications of Neural Networks. 2016: 213-226.
- [4] Pirayesh H, Zeng H. Jamming attacks and anti-jamming strategies in wireless networks: a comprehensive survey[J]. IEEE Communications Surveys & Tutorials, 2022, 24(2): 767-809.
- [5] O'Shea T J, Clancy T C, McGwier R W. Recurrent neural radio anomaly detection[J]. arXiv preprint arXiv:1611.00301, 2016.
- [6] Zhang L, Zhao J, Zhang Z, et al. A combination network of CNN and transformer for interference identification[J]. Frontiers in Communications and Networks, 2022, 3: 901842.
- [7] Xu C, Ren J, Yu W, et al. Time-frequency analysis-based deep interference classification for frequency hopping systems[J]. IEEE Wireless Communications Letters, 2023, 12(5): 819-823.

- [8] Manco J, Dayoub I, et al. Spectrum sensing using software defined radio for cognitive radio networks: a survey[J]. IEEE Communications Surveys & Tutorials, 2023, 25(2): 1074-1107.
- [9] Guo X, Feng P, et al. Interference signal feature extraction and pattern classification algorithm based on deep learning[J]. IEEE Access, 2021, 9: 97564-97575.
- [10] Li L, Dong Z, Zhu Z, et al. Deep-learning hopping capture model for automatic modulation classification of wireless communication signals[J]. IEEE Access, 2022, 10: 38998-39010.
- [11] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 7132-7141.
- [12] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]// Advances in Neural Information Processing Systems. 2017: 5998-6008.
- [13] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778.
- [14] Ettus Research. USRP B210 Data Sheet[EB/OL]. <https://www.ettus.com/all-products/ub210-kit/>, 2024-06-15.
- [15] Proakis J G, Salehi M. Digital Communications (5th Edition)[M]. McGraw-Hill, 2008.
- [16] Goldsmith A. Wireless Communications[M]. Cambridge University Press, 2005.
- [17] Ioffe S, Szegedy C. Batch normalization: accelerating deep network training by reducing internal covariate shift[C]// International Conference on Machine Learning (ICML). 2015: 448-456.
- [18] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [19] Kingma D P, Ba J. Adam: a method for stochastic optimization[C]// International Conference on Learning Representations (ICLR). 2015.
- [20] Westall R, et al. QPSK and 16-QAM digital modulator for an OFDM system on a USRP platform[D]. Virginia Tech, 2010.
- [21] O'Shea T J, Roy T, Clancy T C. Over-the-air deep learning based radio signal classification[J]. IEEE Journal of Selected Topics in Signal Processing, 2018, 12(1): 168-179.
- [22] Van Den Oord A, Dieleman S, Zen H, et al. WaveNet: a generative model for raw audio[J]. arXiv preprint arXiv:1609.03499, 2016.
- [23] Savolainen A. Dual-stage deep learning approach for interference classification in wireless communications[C]// IEEE Wireless Communications and Networking Conference (WCNC). 2024.
- [24] Haykin S. Cognitive radio: brain-empowered wireless communications[J]. IEEE Journal on Selected Areas in Communications, 2005, 23(2): 201-220.
- [25] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.